Laporan Riset & Eksekusi Pengganti Skill — Super Dev Builders Ecosystem

Tanggal: 2026-10-04 · **Repo:** `~/super-dev-builders` · **Pemicu:** mandat Owner — *"jika ada skills yang dihapus dikarenakan security/privacy maka harus melakukan riset, pencarian & analisa untuk mencari penggantinya, dan kapabilitas pengganti WAJIB melebihi skill yang dihapus"*.

---

1. Ringkasan eksekutif

Item	Sebelum	Sesudah	Bukti
Custom skill terdaftar	27	**29**	`registry_lint.py` → PASS `custom skills: 29 | profiles: 7`
Skill terpasang di profil divisi	11 (subset, tidak sinkron registry)	**53 operasi pasang, 0 profil hilang**	`reports/installed-skills.json`
Sel parity `<` (lebih rendah) di matriks penggantian	1 (`serving-llms-vllm`)	**0**	`docs/CAPABILITY_REPLACEMENT_MATRIX.md`
Sel parity `n/a` (tidak diganti)	2 (`inference-sh-cli`, `touchdesigner-mcp`)	**0**	idem
Uji otomatis	42 passed	**49 passed**	`pytest tests -q`
Lint + gate	PASS	PASS (`ruff` bersih, `doctor` exit 0, `evidence_lint` PASS)	log perintah di §4

Kesimpulan satu baris: semua skill yang dibuang karena keamanan/privasi kini punya pengganti, dan dua sel yang tadinya berstatus *lebih rendah / tidak diganti* sudah tertutup dengan pengganti yang **terbukti berjalan di host ini** — bukan klaim.

---

2. Apa yang sebenarnya dieksekusi untuk "6 skills baru"

6 skill pengganti hasil pembersihan keamanan **sudah ada sebagai berkas** di `skills/`, tetapi **belum terpasang** ke profil divisi (gap nyata: 11 dari 27 hanya sampai di `~/.hermes/profiles/cc-*/skills/super-dev-builders/`).

Skill	Menggantikan	Alasan skill lama dibuang
`local-media-generation`	`comfyui`	7 CRITICAL: `curl|sh`, obfuscation, path traversal
`model-hub-provenance`	`huggingface-hub`	1 CRITICAL supply-chain (instalasi tanpa checksum)
`public-feed-reader`	`reddit-reading`	1 CRITICAL data exfiltration
`html-to-video-render`	`hyperframes`	7 privilege_escalation (`setup.sh` + sudo)
`local-experiment-tracking`	`weights-and-biases`	exfiltration HIGH + supply_chain
`privilege-free-tooling`	pola `sudo` di `ascii-art` / `llama-cpp` / `vllm` / `lm-eval`	privilege_escalation berulang

Tindakan yang dilakukan sekarang: pemasangan ke seluruh profil yang dipetakan registry (`install_skills.py --all` → 53 operasi, `--main` → 29 operasi ke `~/.hermes/skills/super-dev-builders/`), sehingga gap repo-vs-profil tertutup dan `registry_lint` melaporkan PASS.

---

3. Riset pengganti lanjutan (mandat baru)

3.1 Sel yang masih lemah sebelum riset ini

1. `serving-llms-vllm` → parity **`<`** (alasan lama: "tidak ada GPU, vLLM tidak layak").
2. `inference-sh-cli` → **`n/a`** (dianggap sudah tercakup tool native, padahal kapabilitasnya "menjalankan inferensi LLM lewat CLI/SaaS pihak ketiga").
3. `touchdesigner-mcp` → **`n/a`** (aplikasi berlisensi tidak ada di host).

3.2 Kandidat yang diperiksa (dengan status bukti yang jujur)

Kandidat	Jenis pemeriksaan	Hasil	Keputusan
`vllm-project/vllm` (PyPI)	cek PyPI + kondisi host	butuh GPU untuk performa; `nvidia-smi` tidak ada	**Tolak** sebagai jalur utama (tetap opsi eskalasi bila Owner menyediakan GPU)
`llama-cpp-python` (PyPI 0.3.36)	cek PyPI JSON	hanya **sdist** (tanpa wheel Linux) → perlu kompilasi	Tolak sebagai jalur utama; dipakai hanya bila butuh binding Python
`ggml-org/llama.cpp` — binari rilis	GitHub Releases API	rilis `v0.5.0` **tanpa** binari Linux (hanya `nightly-tag.txt`)	Tolak jalur binari → **build dari source, tag+commit dipin**
`ggml-org/llama.cpp` — build source	cmake build nyata di host	berhasil; `llama-server --version` = `0.5.0-dev (build 1, commit 7fe450e)`, binari statis 18 MB	**DIPILIH** untuk penggantian `serving-llms-vllm` + `inference-sh-cli`
HuggingFace langsung (model)	`curl` HEAD	`huggingface.co` & `hf-mirror.com` **tidak dapat dijangkau** (mirror me-redirect ke HF)	Tolak; catat sebagai fakta lingkungan
ModelScope (model)	HEAD + API metadata	**dapat dijangkau**; `sha256` tersedia per file	**DIPILIH** sebagai sumber model + verifikasi hash
Ollama OCI registry (model)	HTTP API manifest	**dapat dijangkau**; layer memuat **digest sha256**	Dipilih sebagai sumber alternatif (provenance kuat)
TouchDesigner (aplikasi)	fakta platform/lisensi	proprietary, Windows/macOS; tidak ada di host Linux	Tolak sebagai basis pengganti
Engine visual realtime alternatif	uji nyata di host	Chromium/Playwright **WebGL aktif** (`WebKit WebGL | WebGL 1.0 (OpenGL ES 2.0 Chromium)`), dapat dikendalikan dari luar proses, dapat direkam	**DIPILIH** untuk penggantian `touchdesigner-mcp`

Kandidat	Jenis pemeriksaan	Hasil	Keputusan
Kandidat lain (Godot, Natron, cables.gl, Blender-MCP, dll.)	**belum diuji**	hanya pertimbangan desain di kepala, **tanpa** metadata terverifikasi	Ditandai *belum dievaluasi* — **tidak** dipakai sebagai dasar klaim

> Catatan kejujuran: kandidat di baris terakhir **tidak** saya klaim terverifikasi. Hanya kandidat yang punya baris bukti di atas yang dipakai untuk keputusan.

3.3 Dua skill baru hasil riset

A. **`local-llm-serving`** — menggantikan `serving-llms-vllm`, `inference-sh-cli`, dan menutup jalur model `llama-cpp`. - Binari dibangun dari source pada **tag** **`v0.5.0`** **(commit** **`7fe450e`** **)**, statis (`-DBUILD_SHARED_LIBS=OFF`), tanpa `sudo`, tanpa `curl | sh`. - API kompatibel OpenAI: `/health`, `/v1/models`, `/v1/chat/completions`. - Model: `qwen2.5-0.5b-instruct-q4_k_m.gguf` — **sha256** **`74a4da8c9fdbcd15bd1f6d01d621410d31c6fc00986f5eb687824e7b93d7a9db`**, 491.400.032 byte, terverifikasi sebelum dipakai. - Kenapa **melebihi**: skill lama memerlukan runtime vLLM yang **tidak dapat dipakai sama sekali** di host tanpa GPU; jalur ini **terbukti melayani** (batching paralel terukur) dan tidak bergantung SaaS pihak ketiga.

B. **`realtime-visual-engine`** — menggantikan `touchdesigner-mcp`. - Pipeline: Chromium headless (Playwright) + WebGL/GLSL → frame → `ffmpeg` h264. - Kenapa **melebihi**: skil lama mengasumsikan aplikasi proprietary yang tidak ada di host; pengganti ini jalan di host, tanpa lisensi, lintas platform, dan **dapat dikendalikan agen** lewat jalur kontrol eksternal (UDP/OSC stdlib).

---

4. Bukti empiris (angka mentah, bukan narasi)

4.1 Serving LLM lokal — **`reports/upgrade-evidence/local-llm-serving-bench.json`**

Kondisi host saat uji (penting untuk kejujuran): load average 10,55–13,23; `postgres` dan `chrome` bersaing CPU. Karena itu bench dijalankan **3×** dan dilaporkan **median + min/max** — bukan angka terbaik.

Metrik	Nilai
Kesiapkan server (`/health` ok)	1,02 s; `{"status": "ok"}`
Single request	median **16,35** tok/s (min 12,82 · max 29,34)
4 request paralel (`-np 4`)	agregat median **52,36** tok/s (min 43,99 · max 54,97)
Rasio batching	median **3,2×** (min 1,5× · max 4,29×) — **> 1 di setiap run**
Memori server (RSS)	~600 MB (model 491 MB)
Output nyata	teks Bahasa Indonesia koheren, 51–64 token/permintaan, semua HTTP 200

4.2 Visual realtime — `reports/upgrade-evidence/realtime-visual-report.json` + `realtime-visual.mp4`

Kriteria	Hasil
Konteks WebGL nyata	`WebKit WebGL | WebGL 1.0 (OpenGL ES 2.0 Chromium)`
Kontrol eksternal diterima	`udp_received = ["hue=0.95 zoom=1.35"]`
Kontrol eksternal **menang** atas animasi internal	`udp_override_active = true`
Parameter berbeda → piksel berbeda (waktu sama)	`param_changes_pixels = true`
Frame terakhir bukan hasil default internal	`last_frame_differs_from_internal_default = true`
Determinisme (reproduksi bit-identik)	`applied_value_reproduces_last_frame = true`
Frame unik	32 dari 32
Video h264	`ffmpeg_rc = 0` , 101.705 byte, `ffprobe` OK

4.3 Gate yang dijalankan

```
pytest tests -q                          -> 49 passed
scripts/registry_lint.py                 -> PASS  (custom skills: 29 | profiles: 7 | keep 1
```

```
scripts/doctor.py                    -> exit 0
scripts/evidence_lint.py <2 bukti baru> -> PASS (1 file, 1 record) x2
ruff check skills/                   -> All checks passed!
```

5. Sisa batasan (jujur)

1. **Kecepatan CPU**: 0,5B q4 pada CPU berbagi beban ≈ 16 tok/s single. Ini bukan pengganti GPU untuk beban produksi besar.
2. **FPS visual software-GL** ≈ 6–12 fps pada 480×270 (SwiftShader). Pengganti setara TouchDesigner hanya bila GPU tersedia; jangan klaim "60 fps".
3. **Fitur visual lanjutan** (live video-in, mixing multi-layer, MIDI penuh) belum ada; butuh pass shader tambahan/pustaka OSC.
4. **Model & tool pihak ketiga** tetap butuh audit berkala; versi dipin hari ini bisa berubah besok.
5. `release_check.py` tanpa `--project` memang FAIL (gate proyek, bukan gate ekosistem) — dijalankan per-target saat rilis, bukan untuk pekerjaan ini.
6. Skill pihak ketiga (Superpowers, Trail of Bits, Sentry, Anthropic, GitHub MCP, Context7, Crawlee, axe-core, Lighthouse) **masih PENDING_APPROVAL Owner** — tidak ada yang dipasang diam-diam.

6. Perubahan berkas pada pekerjaan ini

Berkas	Perubahan
`skills/local-llm-serving/**`	**baru** — SKILL.md + `scripts/serve_and_bench.py` (multi-run, median, metadata bukti)
`skills/realtime-visual-engine/**`	**baru** — SKILL.md + `scripts/render_shader.py` (WebGL + kontrol UDP/OSC + ffmpeg)
`skills/model-hub-provenance/scripts/fetch_gguf.py`	ditambah jalur ModelScope + pin sha256 + verifikasi ukuran
`registry/skills.yaml`	+2 entri (29), `approved_custom_count: 29`, klaim parity + bukti
`registry/tools.yaml`	+ `llama_cpp_server`, `ffmpeg`, `chromium_headless_webgl`; bagian baru

Berkas	Perubahan
	`model_sources` (termasuk catatan HF diblokir)
`scripts/registry_lint.py`	hitung dari `approved_custom_count`; error bila menyusut < 21
`docs/CAPABILITY_REPLACEMENT_MATRIX.md`	semua sel `<` dan `n/a` ditutup + bukti
`tests/test_replacement_skills.py`	**baru** — 7 test penjaga klaim parity & kriteria bukti
`reports/upgrade-evidence/*`	bukti: bench JSON, render report JSON, mp4, 4 PNG (frame + kausalitas)

7. Langkah berikut yang disarankan (butuh keputusan Owner)

1. **Setujui/tolak** `docs/00_MASTER_BLUEPRINT_V2.2.html` addendum (jumlah skill resmi 29) — agar dokumen acuan tidak lagi berbeda dengan registry.
2. **Pilih mode binari**: pertahankan build-source (butuh ~4 menit rebuild saat upgrade) atau izinkan mirror binari dengan checksum.
3. Bila GPU tersedia: aktifkan `vllm` sebagai jalur throughput tinggi dan jalankan ulang bench sebagai pembanding.
4. Skill pihak ketiga yang masih PENDING: putuskan satu per satu (rekomendasi saya: mulai dari `anthropics/skills` untuk frontend/webapp-testing karena lisensinya belum jelas — minta konfirmasi dulu).